

CardiOLA — Fase 5

Ir Além 1 — IA Generativa e Extração de Informações Clínicas

1. Objetivo

Este componente estende o assistente da Fase 5 para interpretar anotações clínicas escritas em linguagem livre (texto não estruturado) e transformá-las em um formato estruturado (JSON), utilizando um modelo de linguagem (Gemini) e técnicas de prompting. O objetivo não é gerar diagnóstico, mas demonstrar como IA Generativa pode apoiar a organização de informação clínica para uso posterior por outros módulos do sistema.

2. Fluxo utilizado

Texto clínico simulado (linguagem livre) → Prompt estruturado com schema fixo → Chamada ao modelo Gemini (com retry e espera entre chamadas) → Extração e validação do JSON retornado → Registro do resultado como evidência.

3. Técnicas de IA Generativa aplicadas

- **Prompting estruturado (zero-shot com schema fixo):** o prompt instrui o modelo a devolver exclusivamente um JSON seguindo um formato pré-definido (campos como idade, sintomas, sinais vitais, tabagismo, comorbidades e nível de urgência sugerido), em vez de texto livre. Isso é o que torna a saída confiável o suficiente para alimentar outro sistema sem interpretação manual.
- **Modelo com alias estável (gemini-flash-latest):** em vez de um nome de versão fixo, foi usado o alias mantido pelo Google apontando sempre para a versão estável mais recente do Flash, reduzindo o risco de o notebook quebrar por descontinuação de modelo — problema observado durante o desenvolvimento.
- **Retry com backoff exponencial:** chamadas à API gratuita do Gemini podem falhar temporariamente por limite de uso (erros 429/503). O código tenta novamente automaticamente, aumentando o tempo de espera a cada tentativa (5s, 10s, 20s...), até 5 tentativas, sem exigir intervenção manual.
- **Espaçamento entre chamadas:** uma pausa fixa de 8 segundos entre o processamento de cada texto reduz a chance de esbarrar no limite de requisições por minuto do plano gratuito.

4. Estrutura da saída (schema JSON)

Cada texto clínico processado gera um objeto JSON com os seguintes campos:

```
idade · sexo · sintomas (lista) · tempo_sintomas · sinais_vitais (pressao_arterial,
frequencia_cardiaca_bpm) · tabagismo (status, detalhes) · comorbidades (lista) ·
medicacoes_em_uso (lista) · historico_familiar · nivel_urgencia_sugerido (baixo / medio
/ alto)
```

Campos não mencionados no texto original são preenchidos como `null`, em vez de inventados — decisão deliberada para não introduzir informação clínica que o texto de origem não sustenta.

5. Entrada e evidência

Foram processados 3 textos clínicos simulados (não são dados reais de pacientes), cobrindo cenários distintos: um caso de sintomas agudos sugerindo urgência (dor torácica, sudorese), um

caso de rotina sem sintomas relevantes, e um caso intermediário com fatores de risco (ex-tabagismo, diabetes). O resultado de cada execução — os 3 textos originais e os respectivos JSONs extraídos — está registrado no notebook `ir_alem_1_extracao_clinica.ipynb` e no arquivo `resultados_extracao_clinica.json`, ambos na pasta `ir_alem/` do repositório.

6. Limitações

- O plano gratuito da API do Gemini impõe limites de requisições por minuto e por dia; em uso intenso de testes, esse limite foi atingido durante o desenvolvimento, o que motivou a lógica de retry descrita na Seção 3.
- A extração depende da qualidade do texto de entrada; textos ambíguos ou incompletos no mundo real podem gerar campos nulos ou classificações de urgência menos precisas do que as obtidas com os 3 textos de teste, escritos de forma relativamente clara.
- Este componente é uma demonstração acadêmica de extração estruturada via IA Generativa — não constitui ferramenta de diagnóstico e não deve ser usado para decisões clínicas reais.